

RAG 系统技术选型报告

RAG（检索增强生成）是当前最主流的大模型应用架构。它通过检索外部知识库来增强 LLM 的回答能力，减少幻觉。一个完整的 RAG 系统包含：文档解析、文本分块、向量化、向量存储、检索、重排、生成等环节。

一、向量数据库对比

数据库	定位	最大规模	分布式	适用场景
FAISS	向量检索库	千万级	否	本地实验
Chroma	轻量向量库	十万级	否	原型开发
Milvus	生产级向量库	十亿级	是	生产部署
Pinecone	云向量服务	十亿级	是	SaaS场景

二、RAG 优化要点

- 文档解析：使用 Unstructured 处理复杂 PDF，保留表格和图片信息
- 分块策略：语义分块优于固定长度分块，保持上下文完整性
- 检索优化：混合检索（BM25 + 向量）+ Rerank 重排提升精度
- 评估体系：使用 RAGAs/DeepEval 量化评估，持续迭代优化