

RAG 系统技术选型与优化报告

RAG（检索增强生成）通过检索外部知识库来增强大模型的回答能力，减少幻觉。一个完整的 RAG 系统包含文档解析、文本分块、向量化、向量存储、检索、重排、生成等环节。Naive RAG 的问题在于检索精度不足，Advanced RAG 通过混合检索和重排来解决。

一、向量数据库对比

数据库	定位	最大规模	分布式	适用场景
FAISS	向量检索库	千万级	否	本地实验
Chroma	轻量向量库	十万级	否	原型开发
Milvus	生产级向量库	十亿级	是	生产部署
Pinecone	云向量服务	十亿级	是	SaaS场景

二、检索优化策略

混合检索结合了 BM25 关键词检索和向量语义检索的优势。BM25 擅长精确关键词匹配，向量检索擅长语义相似度匹配。通过 RRF（Reciprocal Rank Fusion）融合两路检索结果，取长补短。

三、Rerank 重排

CrossEncoder 将 Query 和 Document 拼接后一起编码，能捕捉更细粒度的语义关系。它的精度高于 Bi-Encoder（向量检索用的），但速度慢，适合对 Top-K 结果做精排。典型的两阶段检索架构：第一阶段 BM25+向量粗召回，第二阶段 CrossEncoder 精排。

四、Advanced RAG 优化要点

- 1. 文档解析：按元素类型解析，表格整体保留不切碎
- 2. 混合检索：BM25（关键词）+ 向量（语义）双路召回
- 3. RRF 融合：融合两路检索结果，综合排名
- 4. Rerank 重排：CrossEncoder 精排，提升 Top-K 精度
- 5. 向量库：Milvus 生产级部署，支持十亿级数据